Relatório Mineração de Dados

Anime DataSet 2022

Douglas Schindler Mendes
João Victor Schamne
douglasmendes@alunos.utfpr.edu.br
joaoschamne@alunos.utfpr.edu.br
Universidade Tecnológica Federal do Paraná
Curitiba, Paraná

Abstract

In this work, we did a study to analyze which animes are well evaluated and which are the characteristics of the preferred animes of users in general. The motivation for this theme comes from a common interest. For this, we choose a dataset that has several data about anime. The data source we use is available on Kaggle at :

https://www.kaggle.com/datasets/vishalmane10/anime-dataset-2022.

Keywords: datasets, animes, machine learning,

1 Introdução

Neste trabalho, realizamos um estudo visando analisar quais animes são bem avaliados e quais são as características dos animes preferidos dos usuários em geral. A motivação para esse tema parte de um interesse em comum. Para isso, escolhemos um dataset que possui vários dados sobre animes. A fonte de dados que utilizamos está disponível no Kaggle neste link: https://www.kaggle.com/datasets/vishalmane10/anime-dataset-2022

2 Descrição dos dados estudados

O conteúdo do dataset "Anime DataSet 2022" foi extraído do site https://www.anime-planet.com/, e possui 18495 linhas e 17 colunas:

Descrição das colunas:
Rank :qual a posição o anime ocupa no ranking
Name: nome do anime
JapaneseName: nome em japones
Type: tipo (OVA, lançado na TV, filmes, lançado na web)
Episodes: quantidade de episódios
Studio: estúdio que fez o anime
ReleaseSeason: estacao do ano que foi lancado
Tags:categorias (acao, aventura, fantasia, shounen, demonios, etc)
Rating: avaliação do anime

In: Tutoriais do WebMedia, Curitiba, Brasil. Anais Estendidos do Simpósio Brasileiro de Sistemas Multimídia e Web (WebMedia). Porto Alegre: Sociedade Brasileira de Computação, 2022.
© 2023 SBC – Sociedade Brasileira de Computação.
ISSN 2596-1683

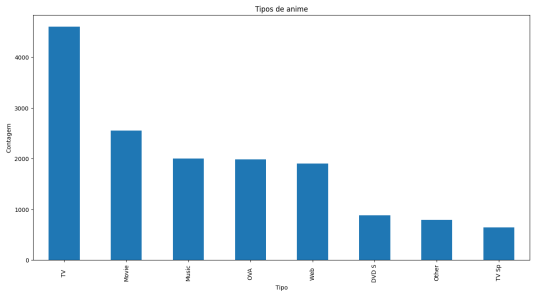

Figure 1. Tipos de anime

ReleaseYear: ano de lançamento
EndYear: ano que finalizou
Description: descrição
ContentWarning: aviso de conteudo (violencia, etc)
RelatedMange: mangás relacionados a esse anime
Relatedanime: animes relacionados a esse anime
Voiceactors: dubladores
staff: equipe de producao do anime

3 Metodologia e técnicas utilizadas

Inicialmente realizamos o estudo do dataset com a análise exploratória, comparando e combinando features para procurar tendências e valores que se destacavam.

Estúdios Comuns
4382
Toei Animation 693
Sunrise 460
J.C.Staff 368
MADHOUSE 352
TMS Entertainment 46
Studio DEEN 274
Production I.G 272
OLM 241
Pierrot 233
A-1 Pictures 223
XEBEC 11
Based on a Manga 4057
Comedy 4049
Action 3389

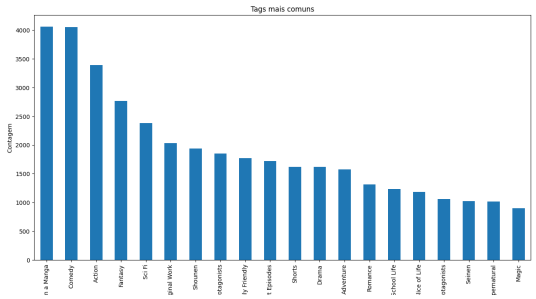

Figure 2. Tags Comuns

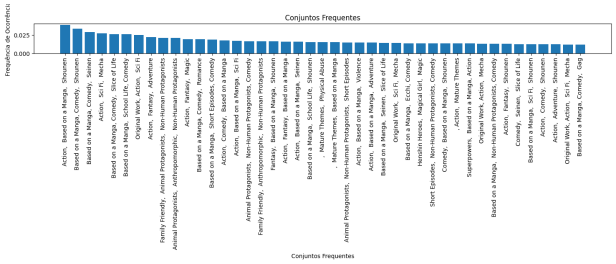

Figure 3. Associação de tags

Fantasy 2769
Sci Fi 2379
Original Work 2031
Shounen 1940
Non-Human Protagonists 1849
Family Friendly 1772
Short Episodes 1721
Shorts 1620
Drama 1617
Adventure 1576
Romance 1316
School Life 1237
Slice of Life 1183
Animal Protagonists 1062
Seinen 1021
Supernatural 1015
Magic 898

A partir deste ponto decidimos fazer classificação dos animes deste dataset, processando algumas fetaures e criando novas a partir de outras, em busca de conseguir classicar os animes entre bem avaliado ou mal avaliado, parâmetros no qual a gente se baseou na feature 'rating' para classificar, onde animes com mais de 3.7 de rating seria bem avaliado e abaixo seria mal avaliado, valor no qual foi decidido na nossa própria interpretação.

Com isso criamos dois arquivos para treinar e classificar o dataset, contendo as seguintes funções e técnicas:

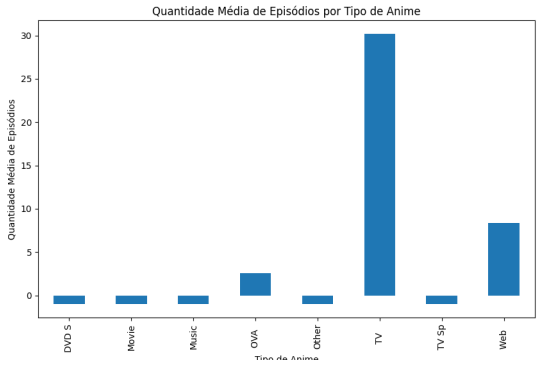

Figure 4. Media de episodios por tipo de mídia

PreparaFeatures Carregamento de arquivos: O código carrega um arquivo CSV contendo informações sobre animes e realiza algumas transformações nos dados, como a contagem de valores em colunas específicas e o tratamento de valores ausentes.

Pré-processamento de texto: É realizado o pré-processamento da descrição dos animes. As etapas incluem a conversão para letras minúsculas, remoção de pontuação, remoção de números e remoção de stopwords (palavras comuns que não possuem significado específico). Análise de tópicos nas descrições dos animes:As descrições dos animes são convertidas em vetores numéricos usando a técnica de CountVectorizer. Isso permite representar as palavras presentes nas descrições como recursos numéricos.Um modelo de Latent Dirichlet Allocation (LDA) é criado com o número desejado de tópicos a serem identificados.O modelo de LDA é treinado usando os vetores de descrição dos animes.Para cada tópico identificado pelo modelo, as palavras mais relevantes são armazenadas em uma lista. Essas palavras representam os principais temas associados a cada tópico.Para cada descrição de anime no DataFrame, é determinado o tópico predominante. Caso a descrição seja inválida (contendo apenas espaços em branco), é atribuído o valor -1. Caso contrário, é calculada a probabilidade de cada tópico para a descrição e é atribuído o rótulo do tópico com maior probabilidade.

Salvamento de dados: Os resultados obtidos são salvos em um novo arquivo CSV contendo as características selecionadas, incluindo sentimentos e tópicos identificados

Main

Carregar arquivos de treinamento e teste: A função carregarArquivos() lê o arquivo "Features.csv", gerado pelo código anterior.

Associação de gêneros: A função AssociacaoGeneros(df) executa o algoritmo FP-growth para encontrar conjuntos frequentes de gêneros de animes com base na coluna "Tags". Em seguida, aplica a clusterização usando K-means com o número de clusters igual ao número de conjuntos frequentes

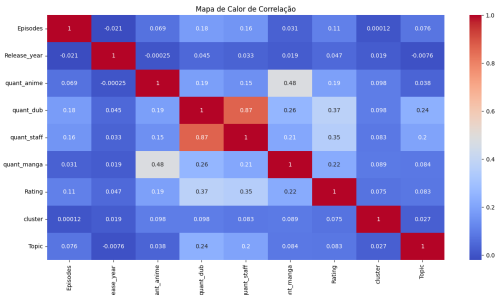

Figure 5. Mapa calor de correlacao features

encontrados. A coluna "cluster" é adicionada ao DataFrame original.

Detecção de anomalias: A função deteccaoAnomalias(df, feature1, feature2) realiza a detecção de anomalias usando o algoritmo Isolation Forest. Ela seleciona duas características (feature1 e feature2) do DataFrame e treina o modelo para identificar instâncias normais e anômalas. As instâncias consideradas normais são mantidas no DataFrame.

Análise da popularidade: A função analisePopularidade(df) realiza a análise de popularidade dos animes. Ela seleciona as características e o alvo para o modelo de classificação, codifica as variáveis categóricas usando OneHotEncoder , treina um classificador SVC (Support Vector Classifier) e em seguida, faz previsões no conjunto de teste.

4 Resultados

Investigamos a relação entre as features existentes e as novas features criadas por meio de um mapa de correlação, com o objetivo de compreender o nível de associação entre elas, especialmente em relação ao rating.

Avaliamos o desempenho do nosso modelo de classificação utilizando métricas como acurácia, precisão, recall e F1-score, obtendo os seguintes resultados:

Acurácia: 90.62
Precisão: 90.13
Recall: 90.62
F1-score: 90.06
precision recall f1-score support
bemAvaliado 0.81 0.60 0.69 532
malAvaliado 0.92 0.97 0.94 2529
accuracy 0.91 3061]
macro avg 0.86 0.79 0.82 3061
weighted avg 0.90 0.91 0.90 3061

Ao analisar as métricas individualmente, observamos que a precisão para a classe 'bemAvaliado' foi de 0.81, indicando que 81 por cento das classificações positivas foram corretas. Já para a classe 'malAvaliado', a precisão foi de 0.92, demonstrando um alto índice de classificações corretas.

No que diz respeito ao recall, obtivemos valores de 0.60 para a classe 'bemAvaliado' e 0.97 para a classe 'malAvaliado'.

O F1-score, uma medida que combina precisão e recall, foi de 0.69 para a classe 'bemAvaliado' e 0.94 para a classe 'malAvaliado', fornecendo uma visão equilibrada do desempenho do modelo.

No geral, nosso modelo alcançou uma acurácia de 90.62, o que indica um bom desempenho em classificar corretamente as amostras.

5 Conclusão

O estudo realizado no dataset "Anime Dataset 2022" proporcionou uma análise interessante sobre os fatores que podem influenciar a avaliação e popularidade de animes. No entanto, algumas dificuldades foram encontradas ao longo do processo.

Uma das principais dificuldades foi o desbalanceamento das classes, ou seja, a distribuição desigual das avaliações dos animes, devido às métricas escolhidas. Isso significa que havia um número significativo de animes com avaliações negativas, enquanto o número de animes com avaliações positivas era relativamente menor. Esse desbalanceamento pode afetar a eficácia dos modelos de classificação e exigir abordagens especiais para lidar com esse problema, tornando difícil encontrar features e parâmetros que consigam identificar a classe com menor valores.

Além disso, algumas features se mostraram ineficazes na previsão da popularidade dos animes. Isso pode ser atribuído à falta de correlação entre essas features e a avaliação dos usuários. No entanto, identificou-se que algumas das melhores features estavam relacionadas ao número de staff e dubladores envolvidos na produção do anime. Isso indica que a qualidade da equipe por trás do anime pode desempenhar um papel importante na determinação da sua popularidade.

Ao analisar os gêneros dos animes, observou-se que há combinações de gêneros que ocorrem com mais frequência do que outras. Isso sugere que certas combinações de gêneros têm maior apelo entre os espectadores e podem ser consideradas tendências comuns na indústria de animes.

No decorrer do estudo, foi necessário descartar os dados que continham valores nulos na coluna de "rating", o que resultou em uma diminuição significativa da quantidade de dados disponíveis. Essa redução prejudicou a robustez das análises e limitou a capacidade de extrair conclusões mais abrangentes.

Por fim, conclui-se que foi possível identificar alguns fatores que podem contribuir para um anime ser bem avaliado e algumas tendências comuns na indústria. No entanto, para uma análise mais completa e precisa, seria necessário um maior número de dados, bem como a inclusão de features adicionais, como comentários de usuários sobre os animes. Essas informações poderiam fornecer insights valiosos para a classificação e compreensão mais aprofundada dos fatores que influenciam a popularidade dos animes.